Лабораторная работа 2

Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

Цель лабораторной работы: изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание: Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.) Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи: обработку пропусков в данных; кодирование категориальных признаков; масштабирование данных.

Ввод [1]:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Ввод [2]:

```
data = pd.read_csv('./restaurant-scores-lives-standard.csv', sep=",")
```

Ввод [3]:

```
# размер набора данных
data.shape
```

Out[3]:

```
(53973, 23)
```

Ввод [4]:

```
# типы колонок
data.dtypes
```

Out[4]:

```
business_id                   int64
business_name                object
business_address             object
business_city                object
business_state               object
business_postal_code         object
business_latitude           float64
business_longitude          float64
business_location            object
business_phone_number       float64
inspection_id                object
inspection_date              object
inspection_score            float64
inspection_type              object
violation_id                 object
violation_description        object
risk_category                object
Neighborhoods (old)         float64
Police Districts            float64
Supervisor Districts        float64
Fire Prevention Districts   float64
Zip Codes                   float64
Analysis Neighborhoods      float64
dtype: object
```

Ввод [5]:

```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

Out[5]:

```
business_id                 0
business_name               0
business_address            0
business_city               0
business_state              0
business_postal_code     1018
business_latitude       19556
business_longitude      19556
business_location       19556
business_phone_number   36938
inspection_id               0
inspection_date             0
inspection_score        13610
inspection_type             0
violation_id            12870
violation_description   12870
risk_category           12870
Neighborhoods (old)     19594
Police Districts        19594
Supervisor Districts    19594
Fire Prevention Districts    19646
Zip Codes               19576
Analysis Neighborhoods  19594
dtype: int64
```

Ввод [6]:

```
# Первые 5 строк датасета
data.head()
```

Out[6]:

	business_id	business_name	business_address	business_city	business_state	business_postal
0	101192	Cochinita #2	2 Marina Blvd Fort Mason	San Francisco	CA	
1	97975	BREADBELLY	1408 Clement St	San Francisco	CA	
2	92982	Great Gold Restaurant	3161 24th St.	San Francisco	CA	
3	101389	HOMAGE	214 CALIFORNIA ST	San Francisco	CA	
4	85986	Pronto Pizza	798 Eddy St	San Francisco	CA	

5 rows × 23 columns

Ввод [7]:

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 53973
```

Обработка пропусков в данных

Простые стратегии - удаление или заполнение нулями

Ввод [8]:

```
# Удаление колонок, содержащих пустые значения
data_new_1 = data.dropna(axis=1, how='any')
(data.shape, data_new_1.shape)
```

Out[8]:

```
((53973, 23), (53973, 8))
```

Ввод [9]:

```
data_new_1.head()
```

Out[9]:

	business_id	business_name	business_address	business_city	business_state	inspection_i
0	101192	Cochinita #2	2 Marina Blvd Fort Mason	San Francisco	CA	101192_2019060
1	97975	BREADBELLY	1408 Clement St	San Francisco	CA	97975_2019072
2	92982	Great Gold Restaurant	3161 24th St.	San Francisco	CA	92982_2017091
3	101389	HOMAGE	214 CALIFORNIA ST	San Francisco	CA	101389_2019062
4	85986	Pronto Pizza	798 Eddy St	San Francisco	CA	85986_2016101

Ввод [10]:

```
# Удаление строк, содержащих пустые значения
data_new_2 = data.dropna(axis=0, how='any')
(data.shape, data_new_2.shape)
```

Out[10]:

```
((53973, 23), (6566, 23))
```

Ввод [11]:

```
data_new_2.head()
```

Out[11]:

	business_id	business_name	business_address	business_city	business_state	business_pos
11	4794	VICTOR'S	210 TOWNSEND St	San Francisco	CA	
172	63652	SFDH - Banquet Main Kitchen	450 Powell St 2nd Floor	San Francisco	CA	
327	328	Miyako	1470 Fillmore St	San Francisco	CA	
372	2684	ERIC'S RESTAURANT	1500 Church St	San Francisco	CA	
397	328	Miyako	1470 Fillmore St	San Francisco	CA	

5 rows × 23 columns

"Внедрение значений" - импьютация (imputation)

Ввод [12]:

```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col,
```

```
Колонка business_latitude. Тип данных float64. Количество пустых значений 195
56, 36.23%.
Колонка business_longitude. Тип данных float64. Количество пустых значений 19
556, 36.23%.
Колонка business_phone_number. Тип данных float64. Количество пустых значений
36938, 68.44%.
Колонка inspection_score. Тип данных float64. Количество пустых значений 1361
0, 25.22%.
Колонка Neighborhoods (old). Тип данных float64. Количество пустых значений 1
9594, 36.3%.
Колонка Police Districts. Тип данных float64. Количество пустых значений 1959
4, 36.3%.
Колонка Supervisor Districts. Тип данных float64. Количество пустых значений
19594, 36.3%.
Колонка Fire Prevention Districts. Тип данных float64. Количество пустых зна
чений 19646, 36.4%.
Колонка Zip Codes. Тип данных float64. Количество пустых значений 19576, 36.2
7%.
Колонка Analysis Neighborhoods. Тип данных float64. Количество пустых значен
ий 19594, 36.3%.
```

Ввод [13]:

```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[13]:

	business_latitude	business_longitude	business_phone_number	inspection_score	Neighbo
0	NaN	NaN	1.415043e+10	NaN	
1	NaN	NaN	1.415724e+10	96.0	
2	NaN	NaN	NaN	NaN	
3	NaN	NaN	1.415488e+10	NaN	
4	NaN	NaN	NaN	NaN	
...	...	...	...	...	
53968	NaN	NaN	NaN	80.0	
53969	NaN	NaN	NaN	NaN	
53970	NaN	NaN	NaN	92.0	
53971	NaN	NaN	NaN	76.0	
53972	NaN	NaN	NaN	80.0	

53973 rows × 10 columns

Ввод [14]:

```
# Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

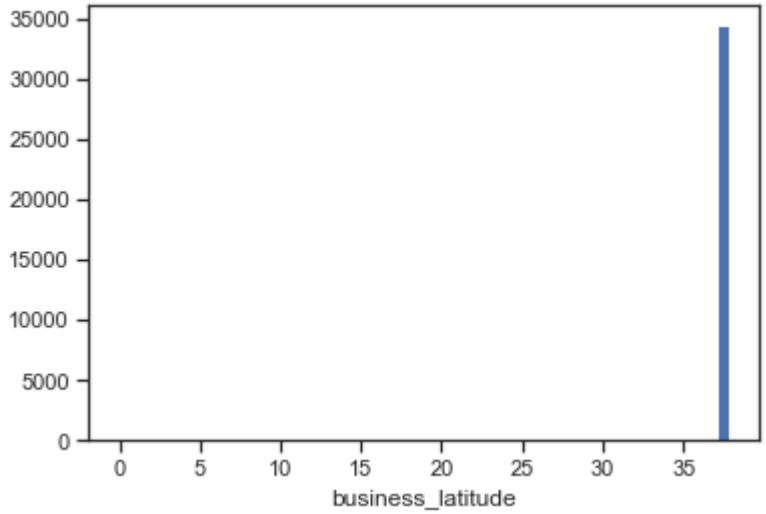

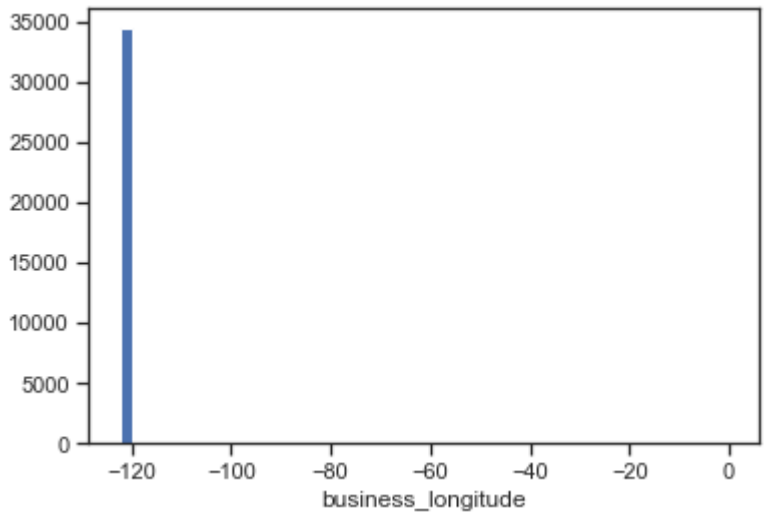

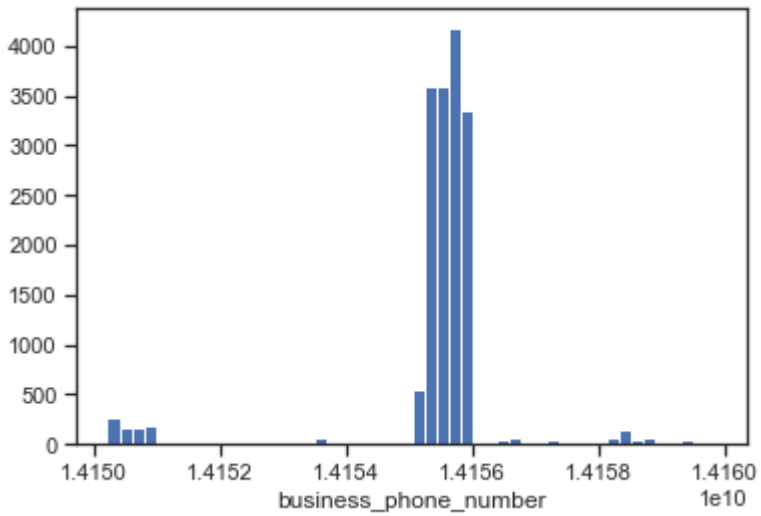

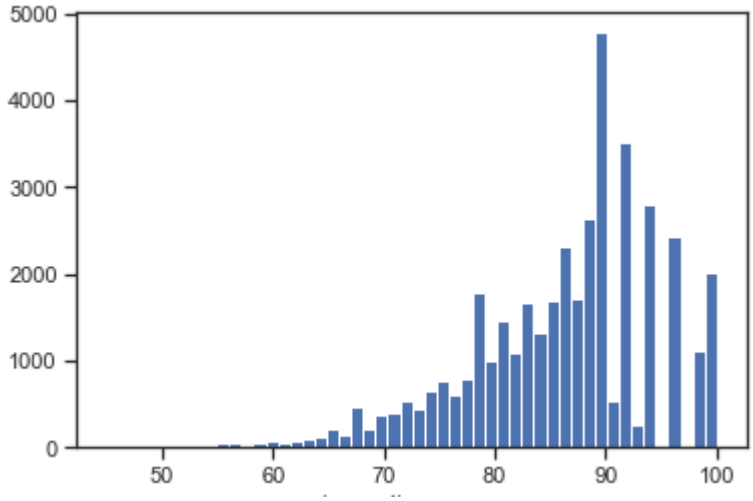
5000
4000
3000
2000
1000
0
50
60
70
80
90
100

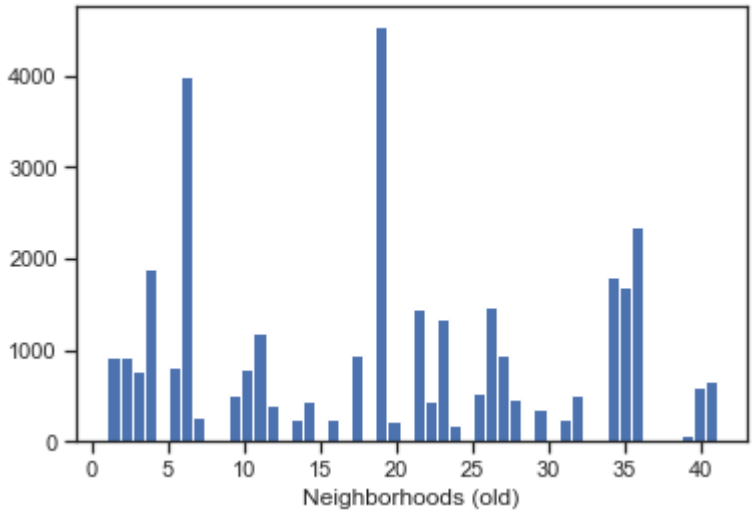
4000
3000
2000
1000
0
0
5
10
15
20
25
30
35
40
Neighborhoods (old)

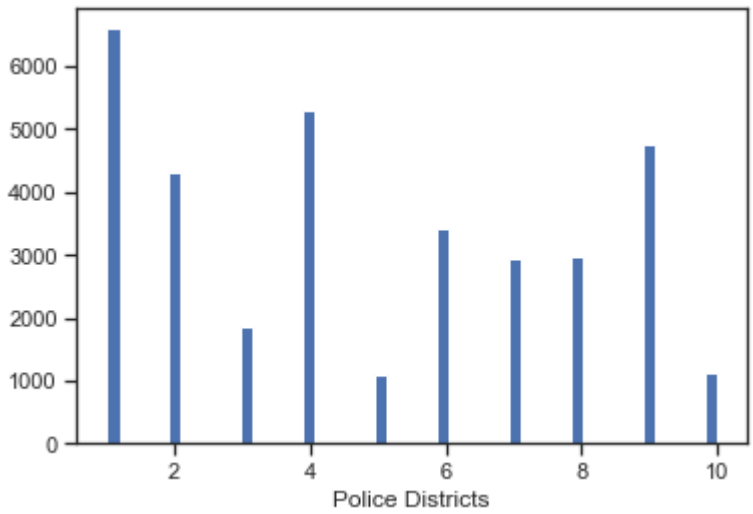
6000
5000
4000
3000
2000
1000
0
2
4
6
8
10
Police Districts

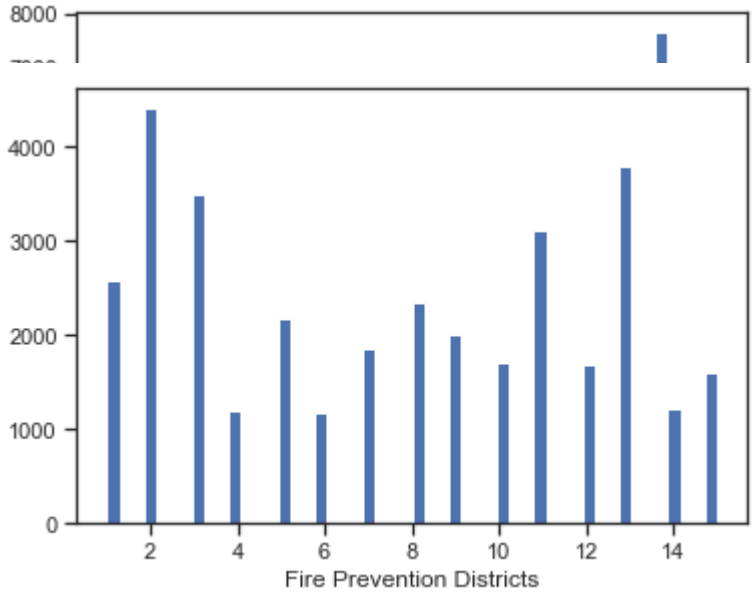
8000
4000
3000
2000
1000
0
2
4
6
8
10
12
14
Fire Prevention Districts

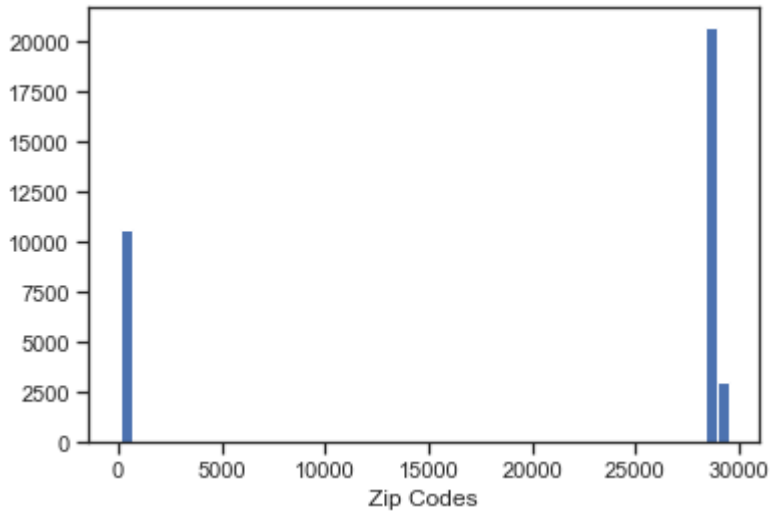
20000
17500
15000
12500
10000
7500
5000
2500
0
0
5000
10000
15000
20000
25000
30000
Zip Codes

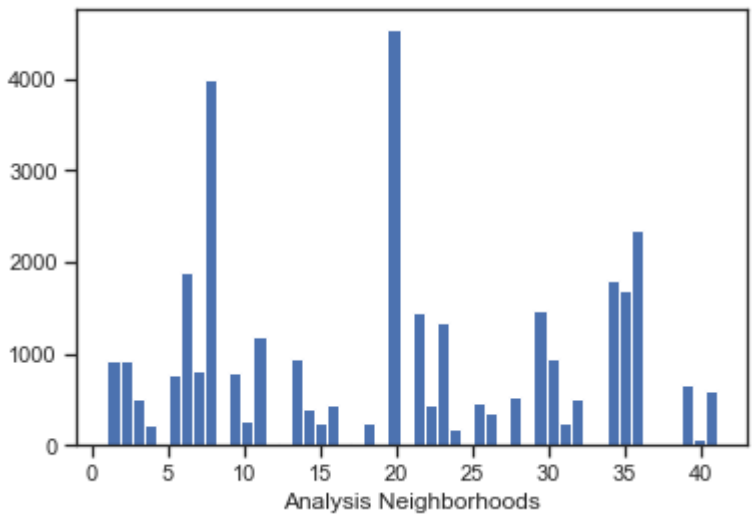
4000
3000
2000
1000
0
0
5
10
15
20
25
30
35
40
Analysis Neighborhoods

Ввод [15]:

```
data_num_inspection_scores = data_num[['inspection_score']]
data_num_inspection_scores.head()
```

Out[15]:

	inspection_score
0	NaN
1	96.0
2	NaN
3	NaN
4	NaN

Ввод [16]:

```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

Ввод [17]:

```
# Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_num_inspection_scores)
mask_missing_values_only
```

Out[17]:

```
array([[ True],
       [False],
       [ True],
       ...,
       [False],
       [False],
       [False]])
```

Ввод [18]:

```
strategies=['mean', 'median', 'most_frequent']
```

Ввод [19]:

```
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_num_inspection_scores)
    return data_num_imp[mask_missing_values_only]
```

Ввод [20]:

```
strategies[0], test_num_impute(strategies[0])
```

Out[20]:

```
('mean',
 array([86.22679186, 86.22679186, 86.22679186, ..., 86.22679186,
        86.22679186, 86.22679186]))
```

Ввод [21]:

```
# Более сложная функция, которая позволяет задавать колонку и вид импьютации
def test_num_impute_col(dataset, column, strategy_param):
    temp_data = dataset[[column]]

    indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(temp_data)

    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(temp_data)

    filled_data = data_num_imp[mask_missing_values_only]

    return column, strategy_param, filled_data.size, filled_data[0], filled_data[fil
```

Ввод [22]:

```
data[['inspection_score']].describe()
```

Out[22]:

	inspection_score
count	40363.000000
mean	86.226792
std	8.462915
min	45.000000
25%	81.000000
50%	87.000000
75%	92.000000
max	100.000000

Ввод [23]:

```
test_num_impute_col(data, 'inspection_score', strategies[0])
```

Out[23]:

```
('inspection_score', 'mean', 13610, 86.22679186383569, 86.226791863835
69)
```

Обработка пропусков в категориальных данных

Ввод [24]:

```
# Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col,
```

```
Колонка business_postal_code. Тип данных object. Количество пустых значений 1
018, 1.89%.
Колонка business_location. Тип данных object. Количество пустых значений 1955
6, 36.23%.
Колонка violation_id. Тип данных object. Количество пустых значений 12870, 2
3.85%.
Колонка violation_description. Тип данных object. Количество пустых значений
12870, 23.85%.
Колонка risk_category. Тип данных object. Количество пустых значений 12870, 2
3.85%.
```

Ввод [25]:

```
cat_temp_data = data[['risk_category']]
cat_temp_data.head()
```

Out[25]:

	risk_category
0	NaN
1	Moderate Risk
2	NaN
3	NaN
4	High Risk

Ввод [26]:

```
cat_temp_data['risk_category'].unique()
```

Out[26]:

```
array([nan, 'Moderate Risk', 'High Risk', 'Low Risk'], dtype=object)
```

Ввод [27]:

```
cat_temp_data[cat_temp_data['risk_category'].isnull()].shape
```

Out[27]:

```
(12870, 1)
```

Ввод [28]:

```
# Импьютация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

Out[28]:

```
array([['Low Risk'],
       ['Moderate Risk'],
       ['Low Risk'],
       ...,
       ['Moderate Risk'],
       ['Moderate Risk'],
       ['Low Risk']], dtype=object)
```

Ввод [29]:

```
# Пустые значения отсутствуют
np.unique(data_imp2)
```

Out[29]:

```
array(['High Risk', 'Low Risk', 'Moderate Risk'], dtype=object)
```

Ввод [30]:

```
# Импьютация константой
imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='NA')
data_imp3 = imp3.fit_transform(cat_temp_data)
data_imp3
```

Out[30]:

```
array([['NA'],
       ['Moderate Risk'],
       ['NA'],
       ...,
       ['Moderate Risk'],
       ['Moderate Risk'],
       ['Low Risk']], dtype=object)
```

Ввод [31]:

```
np.unique(data_imp3)
```

Out[31]:

```
array(['High Risk', 'Low Risk', 'Moderate Risk', 'NA'], dtype=object)
```

Ввод [32]:

```
data_imp3[data_imp3=='NA'].size
```

Out[32]:

```
12870
```

Преобразование категориальных признаков в числовые

Ввод [33]:

```
cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc
```

Out[33]:

	c1
0	Low Risk
1	Moderate Risk
2	Low Risk
3	Low Risk
4	High Risk
...	...
53968	Moderate Risk
53969	Low Risk
53970	Moderate Risk
53971	Moderate Risk
53972	Low Risk

53973 rows × 1 columns

Кодирование категорий целочисленными значениями (label encoding)

Использование LabelEncoder

Ввод [34]:

```
from sklearn.preprocessing import LabelEncoder
```

Ввод [35]:

```
cat_enc['c1'].unique()
```

Out[35]:

```
array(['Low Risk', 'Moderate Risk', 'High Risk'], dtype=object)
```

Ввод [36]:

```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

Ввод [37]:

```
# Наименования категорий в соответствии с порядковыми номерами

# Свойство называется classes, потому что предполагается что мы решаем
# задачу классификации и каждое значение категории соответствует
# какому-либо классу целевого признака

le.classes_
```

Out[37]:

```
array(['High Risk', 'Low Risk', 'Moderate Risk'], dtype=object)
```

Ввод [38]:

```
cat_enc_le
```

Out[38]:

```
array([1, 2, 1, ..., 2, 2, 1])
```

Ввод [39]:

```
np.unique(cat_enc_le)
```

Out[39]:

```
array([0, 1, 2])
```

Кодирование категорий наборами бинарных значений

Ввод [40]:

```
from sklearn.preprocessing import OneHotEncoder
```

Ввод [41]:

```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
```

Ввод [42]:

```
cat_enc.shape
```

Out[42]:

```
(53973, 1)
```

Ввод [43]:

```
cat_enc_ohe.shape
```

Out[43]:

```
(53973, 3)
```

Ввод [44]:

```
cat_enc_ohe.todense()[0:10]
```

Out[44]:

```
matrix([[0., 1., 0.],
        [0., 0., 1.],
        [0., 1., 0.],
        [0., 1., 0.],
        [1., 0., 0.],
        [0., 1., 0.],
        [0., 1., 0.],
        [0., 0., 1.],
        [0., 0., 1.],
        [0., 1., 0.]])
```

Ввод [45]:

```
cat_enc.head(10)
```

Out[45]:

	c1
0	Low Risk
1	Moderate Risk
2	Low Risk
3	Low Risk
4	High Risk
5	Low Risk
6	Low Risk
7	Moderate Risk
8	Moderate Risk
9	Low Risk

Ввод [46]:

```
pd.get_dummies(cat_enc).head()
```

Out[46]:

	c1_High Risk	c1_Low Risk	c1_Moderate Risk
0	0	1	0
1	0	0	1
2	0	1	0
3	0	1	0
4	1	0	0

Ввод [47]:

```
pd.get_dummies(cat_temp_data, dummy_na=True).head()
```

Out[47]:

	risk_category_High Risk	risk_category_Low Risk	risk_category_Moderate Risk	risk_category_nan
0	0	0	0	1
1	0	0	1	0
2	0	0	0	1
3	0	0	0	1
4	1	0	0	0

Масштабирование данных

Ввод [48]:

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

Ввод [49]:

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['inspection_score']])
```

Ввод [50]:

```
plt.hist(data['inspection_score'], 50)
plt.show()
```

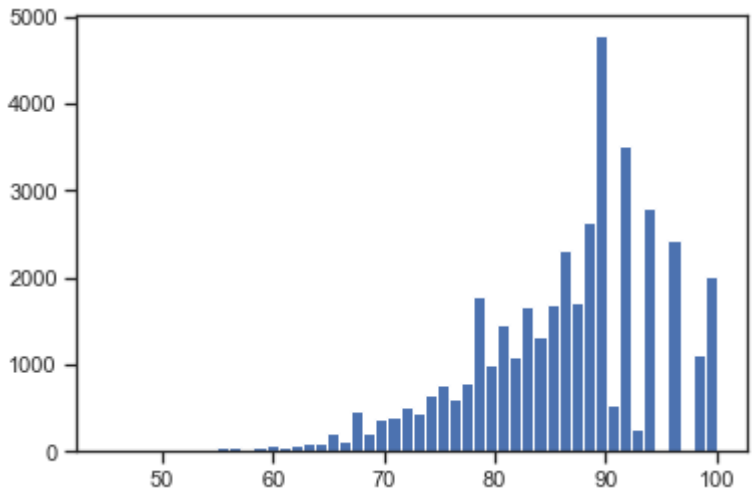

Ввод [51]:

```
plt.hist(sc1_data, 50)
plt.show()
```

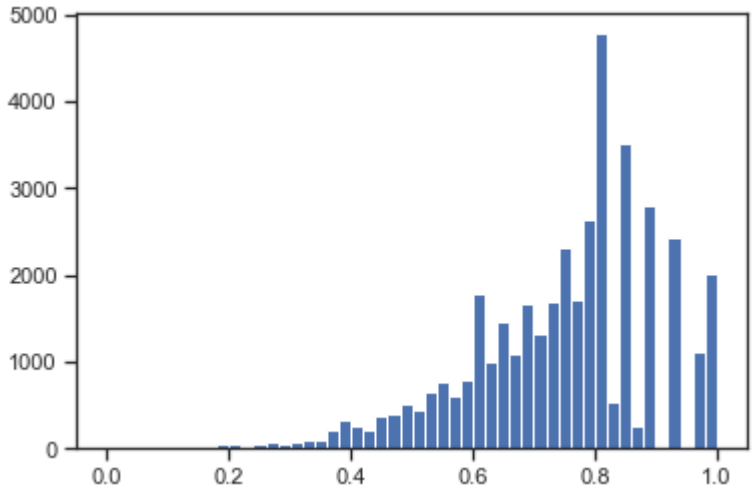

Масштабирование данных на основе Z-оценки - StandardScaler

Ввод [52]:

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['inspection_score']])
```